

共有機材の現場における NFC タッチ起点の タスク自動割当システムと、実績から学習する割当 AI の開発

——予約をなくし、タッチした瞬間に「今やるべき仕事」を渡す——

E2209 指導教員：野村隼人




図1 システム構成 (モジュール-サーバ間は MQTT)

1 はじめに

工場の共有機材（レーザー加工機・旋盤・プレス機など）では、「誰が何に使っているかわからない」「予約はあるのに来ない（ゴースト予約）」「重要な仕事特定の人のみに偏る・忘れられる」という非効率が発生しやすい。製造業では DX を進める人材の不足が課題とされており [1, 2]、専任の IT 担当者がいない中小工場では、計画を立てるコストと、空いている機材や仕事を探すコストが現場の負担になる。

本研究では、各機材に NFC リーダー付きのモジュールを置き、社員証をタッチした瞬間に **その人が今その場所でやるべきタスク** を提示するシステムを開発した。あえて遠隔予約の機能を持たず、物理的なタッチだけを操作の起点にすることで、システム上の状態と現場の実態が常に一致する（ゴースト予約が原理的に起きない）。

チームでの開発のうち、筆者は**タスク割当 AI (WariAthena)** を担当した。割当は「誰にどの仕事を任せると早く終わるか」を、作業ログから学習しながら決める必要がある。本稿の貢献は次の 3 点である。

- **システム** (2 節)：NFC タッチ起点の割当・排他制御・誘導
- **割当 AI** (3 節)：作業者ごとのベイズ線形回帰と Thompson Sampling [3, 6] による文脈付きバンディットとして割当を定式化し、手持ちの仕事量による負荷分散と、資格によるハード制約を組み込んだ
- **評価** (4 節)：シミュレーションで経験年数順などの割当と比べた

2 システム全体の構成

機材モジュール (図 1)：試作機は Raspberry Pi 4 に NFC リーダー (RC522)、2.8 インチ LCD (ILI9341)、物理ボタン 3 個 (左・決定・右)、状態 LED (作業中は赤、それ以外は青) をつないだ。量産は ESP32 へ移す計画である。**通信**：サーバとは MQTT [7] で双方向に通信する。ブローカーは自動探索し、切断は Last Will で即時に死活表

示へ反映する。**サーバ**：Flask と SQLite。

現場の流れ：(1) 空いている機材で社員証をタッチすると、候補タスクが 1 件ずつ LCD に出る。(2) ボタンで承認すると機材がロックされ、他者のタッチは拒否される (排他制御)。候補が無い・すべて断ったときは「フリー利用」としてロックする。(3) 他の機材に本人宛のより重要なタスクがあれば、そちらへ移るかを尋ねる (誘導)。(4) 再タッチで完了し、所要時間を作業ログに記録して機材を解放する。直後に体感難易度 (簡単・普通・難しい) を尋ねる。

管理画面：タスクの登録 (重要度・難易度・数量・期限・必要な資格)、AI による割当とその根拠の表示、稼働状況のダッシュボードを持つ。画面からの機材予約は、ゴースト予約を防ぐため意図的に作っていない。

3 割当 AI：WariAthena

問題設定：割当は、作業者を「腕」、タスクの特徴を「文脈」とする文脈付きバンディット [3] とみなせる。任せたことのない人の実力は分からないため、実績のある人に任せる**活用**と、まだ分からない人に任せてみる**探索**の両立が要る。

文脈：タスク j を作業者 w に任せるときの文脈ベクトル x を

$$x = [y, d, yd, e_{\text{diff}}, e_{\text{perm}}, e_{\text{eq}}] \quad (1)$$

とした。 y は勤続年数 / 30、 d は難易度 (1~5 を 0.15~0.85 に写す)、 e_{diff} は難易度の one-hot、 e_{perm} は必要な資格 (溶接・検査など) の multi-hot、 e_{eq} は機材の one-hot である。資格と機材を入れたのは、難易度だけでは「溶接が得意な人」「旋盤が得意な人」を区別できないためである。

報酬：作業ログから、1 個あたりの所要時間 t (数量で割る) と、同じ難易度の過去の平均 $\bar{t}$ を用いて

$$r = c_f \cdot \bar{t} / t, \quad c_f \in \{1.5, 1.0, 0.5\} \quad (2)$$

とした。 c_f は本人の体感難易度 (簡単・普通・難しい) の係数で、未回答なら t が $\bar{t}$ より 1 割以上速い・遅いかで決める。数量で割らないと、大量のタスクを引いた人が「遅い」と学習されてしまう。

学習：作業者ごとに $r \approx \theta_w^\top x$ の線形モデルを置き、事前分布 $\theta_w \sim \mathcal{N}(\mathbf{0}, 100I)$ 、観測雑音 $\sigma^2 = 0.1$ のベイズ線

形回帰 [4, 5] で事後分布 $\mathcal{N}(\boldsymbol{\mu}_w, \Sigma_w)$ を更新する：

$$\Sigma_w^{-1} \leftarrow \Sigma_w^{-1} + \sigma^{-2} \mathbf{x} \mathbf{x}^\top, \quad (3)$$

$$\boldsymbol{\mu}_w \leftarrow \Sigma_w (\Sigma_{w,\text{old}}^{-1} \boldsymbol{\mu}_{w,\text{old}} + \sigma^{-2} r \mathbf{x}). \quad (4)$$

更新は足し算なので、学習結果は保存せず、作業ログを古い順に再生して組み立て直す（再起動しても失われない）。

選択 (Thompson Sampling)：各作業者の事後分布から $\tilde{\boldsymbol{\theta}}_w$ を 1 本ずつ引き、予測報酬 $\tilde{r}_w = \tilde{\boldsymbol{\theta}}_w^\top \mathbf{x}$ で比べる [3, 6]。実績の少ない人は分布が広く、ときどき大きな値を引くので自然に試される。

負荷分散：予測報酬だけで選ぶと、何でも速いベテランに仕事が集まる。そこで作業者 w の手持ちの残り時間 L_w と、このタスクの見積もり時間 $\hat{T}_j$ （難易度ごとの平均 × 数量）を用いて

$$s_w = \tilde{r}_w / (1 + L_w / \hat{T}_j) \quad (5)$$

で選ぶ（ $\tilde{r}_w < 0$ のときは掛ける）。引き算でなく割り算にしたのは、 c_f のため報酬が速さに比例せず尺度が一定でないからで、割り算なら尺度に依らず、得意・不得意の差が大きい仕事ほど任され続ける。

資格はハード制約：資格（フォークリフト・クレーン・溶接など）は学習させず、AI を呼ぶ前に候補から除く。無資格者に危険作業を任せて失敗から学ぶ設計は成り立たず、勤続年数でも代用できない。

使い方は 2 通り：(a) 現場でタッチされたとき、その人の $\tilde{\boldsymbol{\theta}}_w$ を 1 本だけ引き、候補タスクを予測報酬の順に並べる。(b) 管理画面の「AI 割当」では、タスクに対し上の s_w が最大の人を選び、各候補の期待値・引いた値・手持ち・除外理由を根拠として画面に残す。

4 評価

設定：作業者 6 名（勤続 1～30 年）に、真の時間倍率を隠して与えた。ベテランほど全体に速いが（倍率 1.3–0.5 y ）、個人差 $\pm 30\%$ があり、各人に 1 つ得意な作業（溶接・検査・プレスのいずれか、倍率 $\times 0.6$ ）がある。タスクは難易度 1～5（標準 1～10 分/個）、数量 1～5、種類 4 通りを一樣に生成し、1 ラウンド 6 件を順に割り当て、ラウンドの終わりに全員が作業を終えてログに加わる。150 ラウンド、20 試行の平均をとった。割当 AI は実装をそのまま呼んだ。

指標：(i) **適性比：**任せた人の時間倍率 / そのタスクに最適な人の倍率（1 が最良）、(ii) **完了時間：**1 ラウンドで最も遅い人が終わるまでの時間、(iii) **偏り：**最も多く担当した人の割合。(i)(ii) は学習後（51 ラウンド目以降）で測った。

表1 割当方式の比較（20 試行の平均）

方式	適性比	完了時間 [分]	偏り
ランダム	1.73	44.4	19%
順番（ラウンドロビン）	1.72	34.7	17%
経験年数が最長の人	1.27	63.7	100%
提案（負荷分散なし）	1.03	32.4	42%
提案	1.16	25.4	27%
参考：真の適性を知る	1.21	23.6	24%

参考：真の倍率を知り、最も早く終わる人へ任せる貪欲法

結果（表 1）：経験年数で選ぶと全件がベテラン 1 人に集まり（偏り 100%）、他の人が遊ぶため完了時間が最も長い。ランダムや順番は得意でない人に任せるので適性比が 1.7 と悪い。

負荷分散なしの提案は、学習後はほぼ常に最適な人を選べる（適性比 1.03）。作業ログだけから隠れた得意分野を見つけられている。ただし得意な人に仕事が集まり（偏り 42%）、完了時間は順番とあまり変わらない。

負荷分散を加えた提案は、得意な人が埋まれば次に向く人へ回すため適性比は 1.16 に上がるが、完了時間は 25.4 分で、経験年数による割当より 60%、順番より 27% 短い。真の適性を知る貪欲法（23.6 分）との差は 8% である。「各人に一番向く仕事」と「全体が早く終わる割当」は一致せず、後者には負荷分散が要る。

5 まとめと今後の展望

NFC タッチを起点とするタスク割当システムと、作業ログから各人の得意・不得意を学び、負荷を分散しながら割り当てる AI を開発した。シミュレーションでは、真の適性を知る割当に近い完了時間を得た。

限界：評価はシミュレーションのみで、実際の工場の作業ログはまだ無い。作業者の適性は時間とともに変わらないと仮定した（実際は熟練で速くなる）。ログから毎回学習し直すので、ログが増えると計算が重くなる。「指定した人に任せる」タスクは未対応である。

今後の展望：実際の現場でのログの収集と評価、熟練による変化を扱うための古いログの割引、役職の特徴量化、ESP32 版モジュールの製作を進める。

参考文献

- [1] 経済産業省他、『2025 年版ものづくり白書』, 2025.
- [2] 中小企業庁、『2025 年版中小企業白書』, 2025.
- [3] 本多淳也・中村篤祥、『バンディット問題の理論とアルゴリズム』, 講談社, 2016.
- [4] 須山敦志、『ベイズ推論による機械学習入門』, 講談社, 2017.
- [5] C. M. ビショップ、『パターン認識と機械学習 (上)』, 丸善出版, 2012.
- [6] S. Agrawal and N. Goyal, “Thompson sampling for contextual bandits with linear payoffs,” *Proc. ICML*, 2013.
- [7] OASIS, “MQTT Version 5.0,” OASIS Standard, 2019.